# Maximização da probabilidade *a posteriori*

# Máximo a posteriori (MAP)

## Problemas de estimação

- Em muitos casos, os dados observados/medidos são escassos, ruidosos ou desbalanceados.
- Depender apenas da verossimilhança nesse contexto pode levar a estimativas instáveis/inadequadas.
- A abordagem do máximo a posteriori (MAP) incorpora conhecimento (crença) prévio, em formato probabilístico, sobre os parâmetros.

# Máximo a posteriori (MAP) - cont.

**Motivação para MAP:** estimar um parâmetro desconhecido $\theta$ com duas fontes de informação:

1. os **dados observados**;
2. uma **crença prévia** (probabilística) sobre valores possíveis de $\theta$.

**Ideia principal**

Escolher o valor de $\theta$ que fica mais plausível **após observar os dados**.

# Máximo a posteriori (MAP) - cont.

**Exemplo:** Um sensor está realizando medidas da temperatura ambiente.

- A leitura atual sugere um valor elevado.
- Entretanto, pelo histórico e período de medição, sabe-se que temperaturas extremas são muito raras.

 A estimativa final não depende apenas da medida atual, mas do que é razoável (estatisticamente) esperar.

 Essa combinação entre evidência (dados) e conhecimento prévio é a essência do critério MAP.

## Formalismo

Lembrando do teorema de Bayes e considerando que $\mathcal{D}$ representa os dados e $\boldsymbol{\theta}$ os parâmetros, então podemos ter:

$$p(\boldsymbol{\theta}|\mathcal{D}) = \frac{p(\mathcal{D}|\boldsymbol{\theta})\, p(\boldsymbol{\theta})}{p(\mathcal{D})}, \tag{85}$$

em que

- ✓ $p(\boldsymbol{\theta}|\mathcal{D})$: posterior;
- ✓ $p(\mathcal{D}|\boldsymbol{\theta})$: verossimilhança;
- ✓ $p(\boldsymbol{\theta})$: prior;
- ✓ $p(\mathcal{D})$: evidência.

## Formalismo - cont.

**E o que representa cada termo?**

**Prior** $p(\theta)$: o que se acredita antes de olhar os dados.

**Verossimilhança** $p(\mathcal{D}|\theta)$: o quanto os dados combinam com um valor de $\theta$.

**Posterior** $p(\theta|\mathcal{D})$: crença atualizada após observar os dados.

Ou seja,

posterior = dados + conhecimento prévio

**Formalismo - cont.**

O estimador MAP é definido por:

$$\widehat{\boldsymbol{\theta}}_{\text{MAP}} = \arg\max_{\boldsymbol{\theta}} \; p(\boldsymbol{\theta}|\mathcal{D}). \tag{86}$$

Como $p(\mathcal{D})$ não depende de $\boldsymbol{\theta}$, também podemos escrever:

$$\widehat{\boldsymbol{\theta}}_{\text{MAP}} = \arg\max_{\boldsymbol{\theta}} \; p(\mathcal{D}|\boldsymbol{\theta})p(\boldsymbol{\theta}). \tag{87}$$

**Formalismo - cont.**

Podemos ainda considerar a aplicação da função logaritmo na expressão da MAP e temos

$$\widehat{\boldsymbol{\theta}}_{\text{MAP}} = \arg\max_{\boldsymbol{\theta}} \left[\log p(\mathcal{D}|\boldsymbol{\theta}) + \log p(\boldsymbol{\theta})\right]. \tag{88}$$

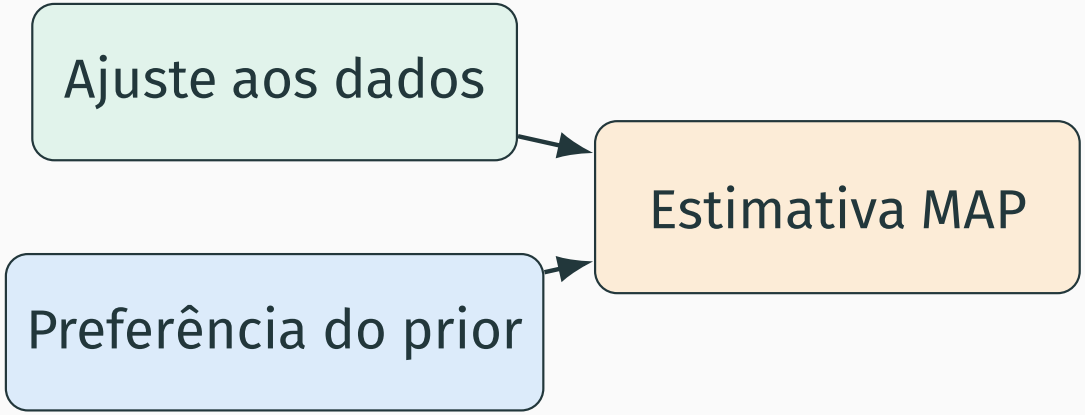
Com isso, podemos "ler" a Equação (88) da seguinte maneira:

- **primeiro termo**: procurar um parâmetro que explique bem os dados;
- **segundo termo**: evitar valores que o prior considera pouco prováveis.

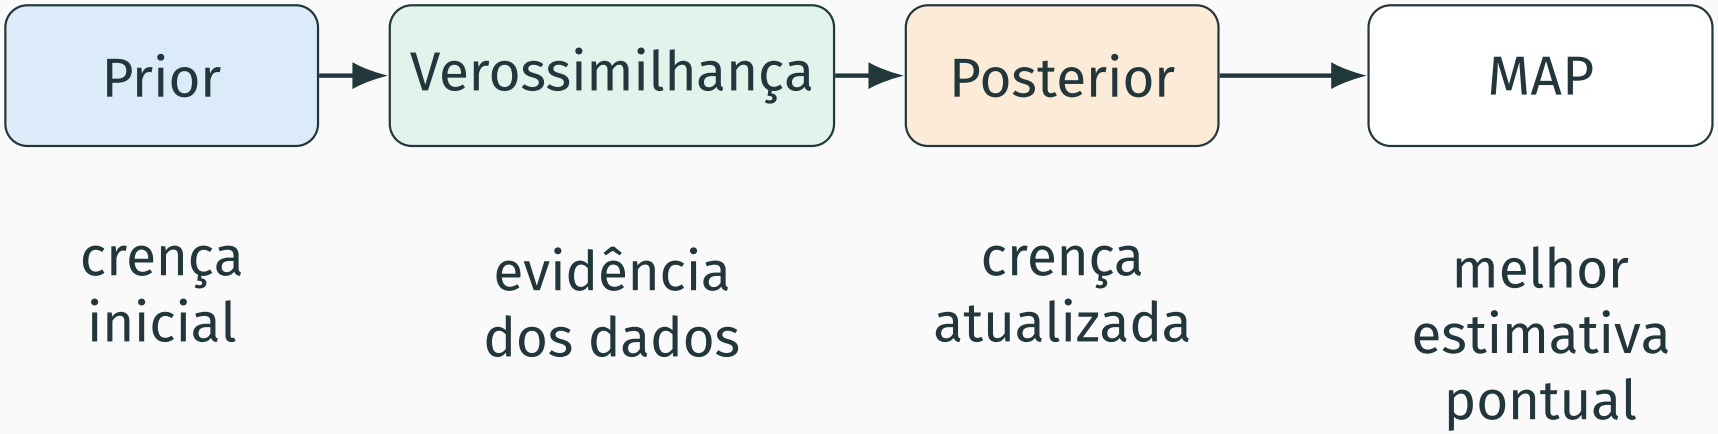
# Máximo a posteriori (MAP) - cont.

**Intuição da fórmula**

- $\log p(\mathcal{D}|\boldsymbol{\theta})$ recompensa bons ajustes aos dados.
- $\log p(\boldsymbol{\theta})$ recompensa valores mais plausíveis (prior).
- MAP busca um compromisso entre os dois efeitos.



# Máximo a posteriori (MAP) - cont.



**E sobre a estimação de máxima verossimilhança?**

O estimador de máxima verossimilhança (MV) é dado por

$$\widehat{\boldsymbol{\theta}}_{\text{MV}} = \arg\max_{\boldsymbol{\theta}} \; p(\mathcal{D}|\boldsymbol{\theta}). \tag{89}$$

Ou seja, o estimador MV utiliza apenas os dados para realizar o cálculo (sem crença sobre os valores dos parâmetros).

# Máximo a posteriori (MAP) - cont.



No caso do MAP, se o prior $p(\theta)$ for uniforme, não há favorecimento de nenhum valor/faixa específico de $\theta$.

Com isso, nesse caso, temos $\widehat{\theta}_{\text{MAP}} = \widehat{\theta}_{\text{MV}}$.

**Importante**

O estimador MV é um caso particular de estimador MAP quando não há preferência prévia relevante.

# Máximo a posteriori (MAP) - cont.

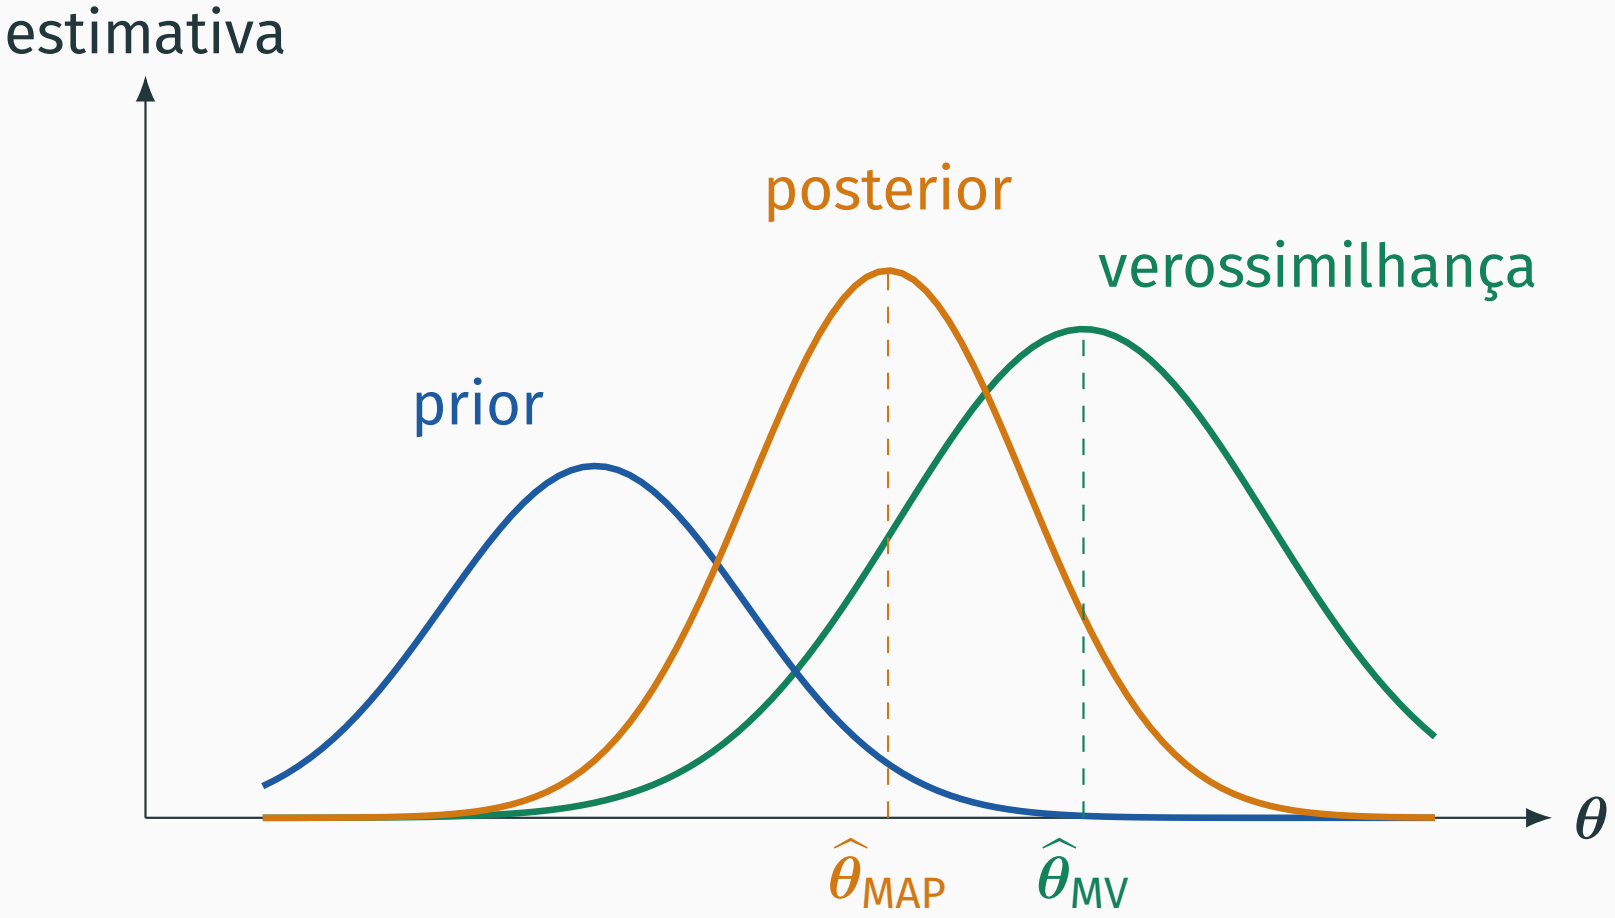



**Figura 7:** A posterior pode deslocar a estimativa em relação ao máximo da verossimilhança devido o prior.

# Máximo a posteriori (MAP) - cont.

Podemos ainda escrever o estimador MAP como um processo de minimização. Nesse caso, considerando a versão com o logaritmo, temos:

$$\widehat{\boldsymbol{\theta}}_{\text{MAP}} = \arg\min_{\boldsymbol{\theta}} \; [-\log p(\mathcal{D}|\boldsymbol{\theta}) - \log p(\boldsymbol{\theta})] \tag{90}$$

A Equação (90) mostra dois aspectos:

1. uma perda referente aos dados, e;
2. uma penalização com relação ao prior.

# Máximo a posteriori (MAP) - cont.

**Em aprendizado de máquinas...**

Redução no desempenho de treinamento para aumentar a generalização: **regularização**. Visa redução de *over-fitting* para se comportar de forma mais adequada em diferentes conjuntos de dados.



Em aprendizado de máquinas, regularizar é muitas vezes **equivalente a escolher um prior**.

# Máximo a posteriori (MAP) - cont.

Desse modo, a Equação (90) pode ter seus termos interpretados como

$$\underbrace{-\log p(\mathcal{D}|\boldsymbol{\theta})}_{\text{erro nos dados}} + \underbrace{-\log p(\boldsymbol{\theta})}_{\text{regularização}}$$

 Isso explica por que muitos problemas regularizados em aprendizado de máquinas têm interpretação bayesiana.

# Máximo a posteriori (MAP) - cont.

## Exemplo

Se $\boldsymbol{\theta} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$, ou seja, o prior possui uma distribuição gaussiana, teremos

$$-\log p(\boldsymbol{\theta}) = \frac{1}{2\sigma^2}\|\boldsymbol{\theta}\|_2^2 + C.$$

Com isso, o estimador MAP é dado por

$$\widehat{\boldsymbol{\theta}}_{\text{MAP}} = \arg\min_{\boldsymbol{\theta}} \left[-\log p(\mathcal{D}|\boldsymbol{\theta}) + \lambda\|\boldsymbol{\theta}\|_2^2\right]. \tag{91}$$



A Equação (91) corresponde à regularização do tipo Ridge, também chamada de regularização de Tikhonov.

# Máximo a posteriori (MAP) - cont.

**Interpretando a penalização ...**

A penalização $\|\theta\|_2^2$ força os parâmetros para valores menores e isso auxilia para:

- evitar valores exagerados;
- reduzir *overfitting*;
- melhorar generalização.

Em linguagem bayesiana (a mesma do MAP) a mensagem seria:

*"antes de ver os dados, acredito que valores muito elevados são improváveis."*

# Máximo a posteriori (MAP) - cont.

## Onde mais em aprendizado de máquinas?

- Regressão logística com penalização $\ell_2$ ou $\ell_1$.
- *Naive* Bayes com suavização e priors conjugados.
- Redes neurais sob interpretação bayesiana simplificada de decaimento de pesos.
- Modelos probabilísticos gráficos com estimação regularizada.

**Regressão logística regularizada**

Sejam dados $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$ com $y_i \in \{0, 1\}$, que fornecem a seguinte expressão para a MV

$$p(y_i|\boldsymbol{x}_i, \boldsymbol{w}) = \sigma(\boldsymbol{w}^T \boldsymbol{x}_i) = \frac{1}{1 + \exp(-\boldsymbol{w}^T \boldsymbol{x}_i)}. \tag{92}$$

Se considerarmos um prior gaussiano aos coeficientes $\mathbf{w}$, ou seja $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma_w^2 \mathbf{I})$, o critério MAP corresponde a minimizar a seguinte expressão:

$$\mathcal{L}(\mathbf{w}) = -\sum_{i=1}^{n} \log p(y_i|\boldsymbol{x}_i, \boldsymbol{w}) + \lambda \|\boldsymbol{w}\|_2^2. \tag{93}$$

**Conclusão:** a forma regularizada ensinada em aprendizado de máquinas tem interpretação probabilística explícita.

**Média de dados gaussianos e prior gaussiano**

Seja um conjunto de amostras com distribuição gaussiana, i.e.

$$x_i \sim \mathcal{N}\left(\mu, \sigma^2\right), \quad i = 1, 2, \ldots, N. \tag{94}$$

Assumimos $\sigma^2$ conhecido e também assumimos uma distribuição para $\mu$ (prior) da seguinte forma:

$$\mu \sim \mathcal{N}\left(\mu_0, \sigma_\mu^2\right). \tag{95}$$

Assim, temos (desprezando constantes) a posterior dada por

$$\log p(\mu|\mathcal{D}) = -\frac{1}{2\sigma^2}\sum_{i=1}^{N}(x_i - \mu)^2 - \frac{1}{2\sigma_\mu^2}(\mu - \mu_0)^2 \tag{96}$$

**Média de dados gaussianos e prior gaussiano - cont.**

Maximizar a posterior é equivalente a minimizar

$$\frac{1}{2\sigma^2}\sum_{i=1}^{N}(x_i-\mu)^2+\frac{1}{2\sigma_\mu^2}(\mu-\mu_0)^2. \tag{97}$$

Derivando e igualando a zero temos

$$\widehat{\mu}_{\text{MAP}}=\frac{\frac{N}{\sigma^2}\bar{x}+\frac{1}{\sigma_\mu^2}\mu_0}{\frac{N}{\sigma^2}+\frac{1}{\sigma_\mu^2}}, \tag{98}$$

em que $\bar{x}=\frac{1}{N}\sum_{i=1}^{N}x_i$.

**Média de dados gaussianos e prior gaussiano - cont.**

De forma equivalente, podemos escrever

$$\widehat{\mu}_{\text{MAP}} = \omega \bar{x} + (1-\omega)\mu_0, \qquad \omega = \frac{N\sigma_\mu^2}{N\sigma_\mu^2 + \sigma^2}. \tag{99}$$



Ou seja, **MAP é uma média ponderada entre a evidência dos dados e a crença prévia.** Em outras palavras, uma média entre o que os dados dizem e o que já era esperado.

# Máximo a posteriori (MAP) - cont.

**Média de dados gaussianos e prior gaussiano - cont.**

## Intuição

- Se $N$ aumenta, $\omega \to 1$ e a estimativa se aproxima de $\bar{x}$.
- Se $\sigma_\mu^2$ é pequena, o prior é muito concentrado e exerce forte atração para $\mu_0$.
- Se $\sigma^2$ é grande, os dados são ruidosos e o prior ganha relevância.

***Takeaway message:*** MAP implementa uma fusão entre conhecimento prévio e informação amostral, com pesos determinados pelas incertezas relativas.

**Média de dados gaussianos e prior gaussiano - cont.**

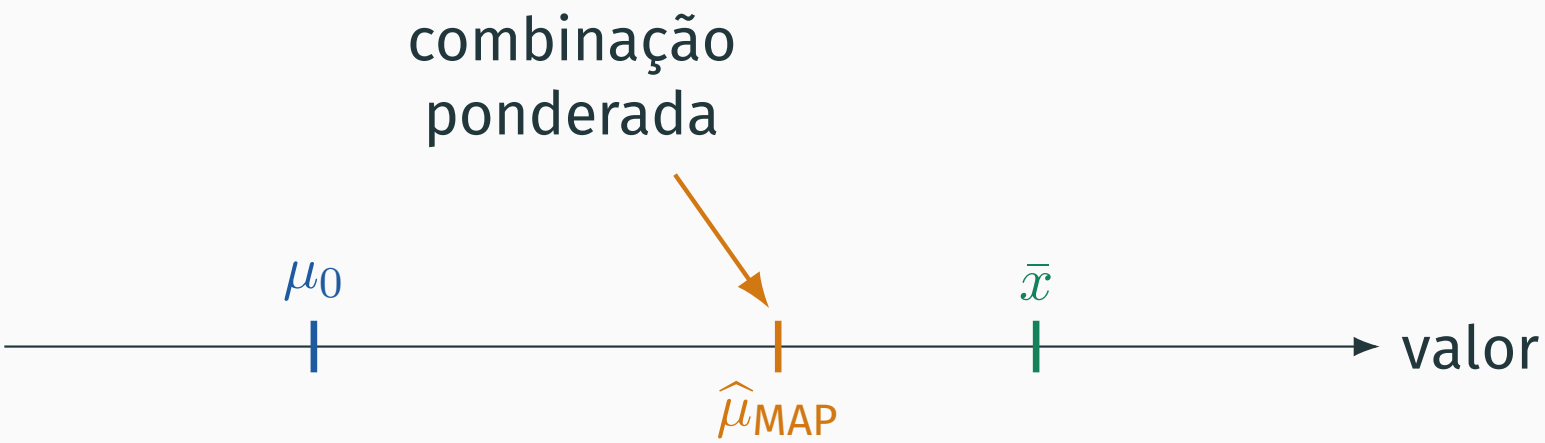



**Figura 8:** Estimação MAP - com poucos dados ou muito ruído, a estimativa puxa mais para o prior.

# Máximo a posteriori (MAP) - cont.

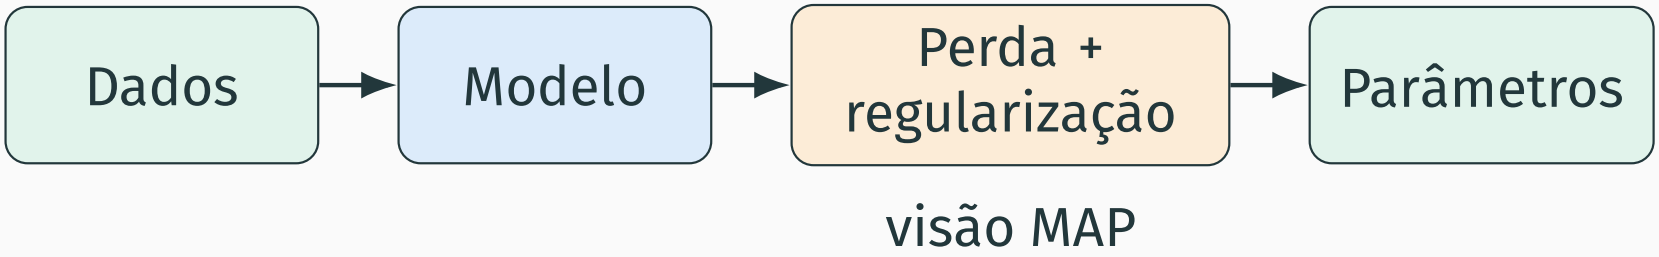



**Figura 9:** Regularização como uma consequência da escolha do prior.

# Máximo a posteriori (MAP) - cont.

## Pontos positivos

- ☺ Introduz conhecimento prévio (probabilístico) de maneira formal e interpretável.
- ☺ Produz estimativas mais estáveis para poucas amostras.
- ☺ Ajuda a evitar *overfitting*.
- ☺ Conecta inferência bayesiana e técnicas de regularização usuais.
- ☺ Em muitos casos, mantém custo computacional similar ao critério MV.

# Máximo a posteriori (MAP) - cont.

## Pontos de atenção

- A escolha do prior pode influenciar fortemente o resultado.
- Um prior mal especificado pode induzir viés indesejado.
- MAP produz um *ponto* estimado, não a posterior completa (que é objeto de interesse da inferência bayesiana).
- Em posteriores multimodais, o modo pode não representar bem a incerteza global.
- Em problemas de alta dimensão, otimização e seleção de hiperparâmetros continuam críticas.