

UFC

UNIVERSIDADE FEDERAL DO CEARÁ
DEPARTAMENTO DE ENGENHARIA DE TELEINFORMÁTICA

Relatório do Trabalho Teórico/Computacional

Maximização da propriedade a posteriori

Ruan Pereira Alves – 569551

11 de novembro de 2026

1 Questão 01: Estimativa MAP da Média de Atributos Gaussianos

1.1 Fundamentação Teórica

Considerando os dados referentes ao atributo `MonthlyCharges` extraído, denotadas por $\mathcal{D} = \{x_1, x_2, \ldots, x_N\}$, assume-se um modelo de verossimilhança gaussiano $x_i \sim \mathcal{N}(\mu, \sigma^2)$ com variância σ^2 conhecida. A função de verossimilhança é dada por:

$$p(\mathcal{D}|\mu) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \tag{1}$$

Assumindo um conhecimento prévio probabilístico (prior) sob a forma de uma distribuição gaussiana para o parâmetro de média $\mu \sim \mathcal{N}(\mu_0, \sigma_\mu^2)$, a densidade a priori vai ser expressa como:

$$p(\mu) = \frac{1}{\sqrt{2\pi\sigma_\mu^2}} \exp\left(-\frac{(\mu - \mu_0)^2}{2\sigma_\mu^2}\right) \tag{2}$$

Pelo Teorema de Bayes, a distribuição a posteriori $p(\mu|\mathcal{D}) \propto p(\mathcal{D}|\mu)p(\mu)$ sob a aplicação do logaritmo resulta na log-posteriori:

$$\log p(\mu|\mathcal{D}) = -\frac{1}{2\sigma^2}\sum_{i=1}^{N}(x_i - \mu)^2 - \frac{1}{2\sigma_\mu^2}(\mu - \mu_0)^2 + C \tag{3}$$

em que C reúne os termos constantes que não dependem de μ. O estimador de Máximo a Posteriori ($\hat{\mu}_{\text{MAP}}$) é obtido minimizando a função de perda logarítmica:

$$\mathcal{L}(\mu) = \frac{1}{2\sigma^2}\sum_{i=1}^{N}(x_i - \mu)^2 + \frac{1}{2\sigma_\mu^2}(\mu - \mu_0)^2 \tag{4}$$

Derivando $\mathcal{L}(\mu)$ em relação a μ e igualando a zero ($\frac{d\mathcal{L}}{d\mu} = 0$), obtém-se:

$$-\frac{1}{\sigma^2}\sum_{i=1}^{N}(x_i - \mu) - \frac{1}{\sigma_\mu^2}(\mu - \mu_0) = 0 \implies \frac{N}{\sigma^2}(\mu - \bar{x}) + \frac{1}{\sigma_\mu^2}(\mu - \mu_0) = 0 \tag{5}$$

onde $\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$ é a média amostral (solução de Máxima Verossimilhança $\hat{\mu}_{\text{MV}}$). Isolando μ, chega-se à expressão analítica do estimador MAP:

$$\hat{\mu}_{\text{MAP}} = \frac{\frac{N}{\sigma^2}\bar{x} + \frac{1}{\sigma_\mu^2}\mu_0}{\frac{N}{\sigma^2} + \frac{1}{\sigma_\mu^2}} = w\bar{x} + (1 - w)\mu_0, \quad \text{com } w = \frac{N\sigma_\mu^2}{N\sigma_\mu^2 + \sigma^2} \tag{6}$$

1.2 Resultados e Discussão

Para o atributo `MonthlyCharges` do dataset com $N = 7043$ amostras, foram calculados a média amostral $\bar{x} = 64{,}7617$ e a variância amostral $\sigma^2 = 905{,}4109$. Considerando o prior com $\mu_0 = 60$ e variâncias $\sigma_\mu^2 \in \{5, 10, 20, 50\}$, os resultados são resumidos na Tabela 1.

Tabela 1: Estimativas MAP da média de `MonthlyCharges` para diferentes variâncias do prior ($\mu_0 = 60$, $N = 7043$).

Variância do Prior (σ_μ^2)	Peso dos Dados (w)	Média MAP ($\hat{\mu}_{\text{MAP}}$)	Média MV ($\hat{\mu}_{\text{MV}}$)
5	0,974966	64,6422	64,7617
10	0,987284	64,7018	64,7617
20	0,993601	64,7315	64,7617
50	0,997434	64,7495	64,7617

Análise do impacto da variância do prior:

1. **Dominância da Evidência Amostral:** Devido ao elevado número de amostras ($N = 7043$), o fator de ponderação $w \to 1$. Isso confirma que quanto maior o volume de dados, menor é a dependência da estimativa em relação à crença inicial.

2. **Efeito de Atração do Prior:** Para valores menores de σ_μ^2 (ex.: $\sigma_\mu^2 = 5$), o prior demonstra maior grau de certeza, deslocando a estimativa de forma mais incisiva em direção a $\mu_0 = 60$. À medida que σ_μ^2 cresce, a incerteza do prior aumenta e a estimativa MAP converge assintoticamente para a solução de máxima verossimilhança $\bar{x}$.

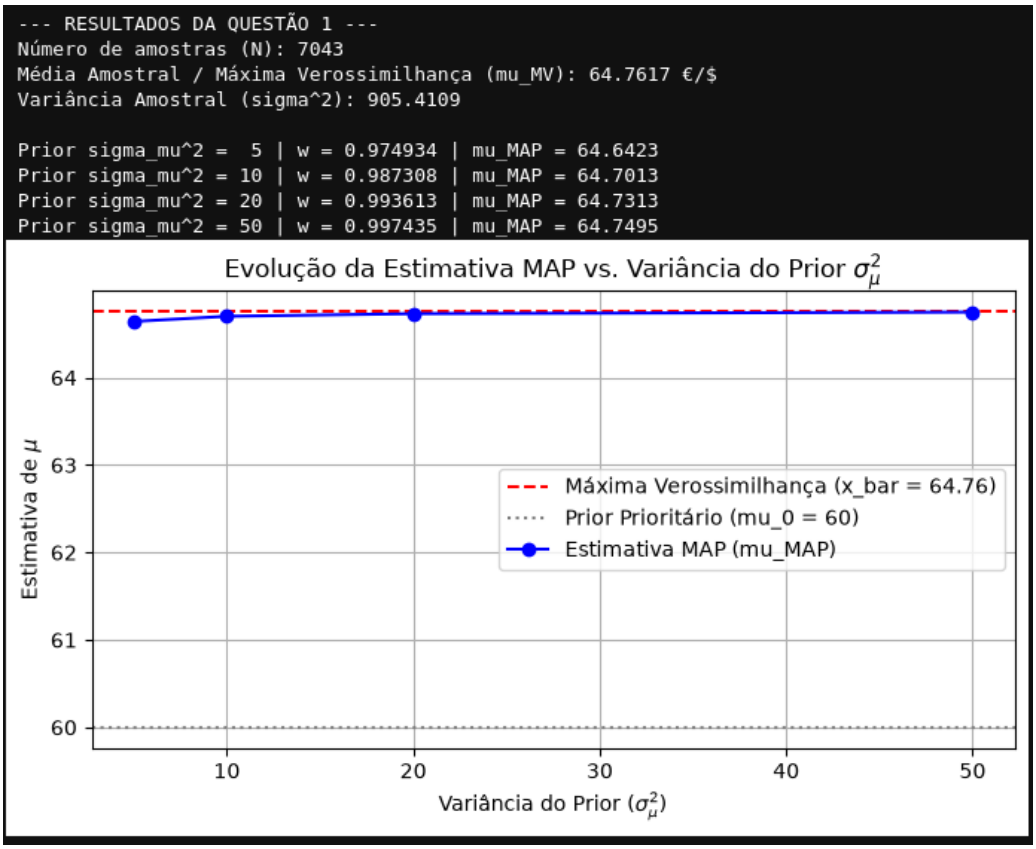


Figura 1: Feito pelo autor.

2 Questão 02: Regressão Linear Simples via Máxima Verossimilhança

2.1 Fundamentação Teórica

Deseja-se prever a variável dependente U (`TotalCharges`) a partir das variáveis independentes G (`tenure`) e T (`MonthlyCharges`). O modelo de regressão linear é definido por:

$$y_i = w_0 + w_1 x_{i1} + w_2 x_{i2} + e_i, \quad e_i \sim \mathcal{N}(0, \sigma_e^2) \tag{7}$$

onde $\mathbf{x}_i = [x_{i1}, x_{i2}]^T$ representam os atributos de `tenure` e `MonthlyCharges`, respectivamente. Na abordagem por Mínimos Quadrados Ordinários (OLS) / Máxima Verossimilhança (MV), os coeficientes $\mathbf{w}_{\text{MV}} = [w_0, w_1, w_2]^T$ são obtidos minimizando o Erro Quadrático Médio (MSE) no conjunto de treino:

$$\text{MSE} = \frac{1}{N_{\text{treino}}} \sum_{i=1}^{N_{\text{treino}}} (y_i - \hat{y}_i)^2 = \frac{1}{N_{\text{treino}}} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 \tag{8}$$

2.2 Resultados e Discussão

O conjunto de dados tratados ($N = 7032$ amostras válidas) foi dividido aleatoriamente em 80% para treinamento ($N_{\text{treino}} = 5625$) e 20% para teste ($N_{\text{teste}} = 1407$). Os coeficientes ajustados e os erros quadráticos médios obtidos são apresentados a seguir:

Tabela 2: Desempenho da Regressão Linear Simples (Máxima Verossimilhança).

Parâmetro / Métrica	Valor Estimado
Coeficiente `tenure` (w_1)	65,3435
Coeficiente `MonthlyCharges` (w_2)	19,7414
Intercepto (w_0)	−1971,5561
MSE - Treinamento	474811,23
MSE - Teste	447720,82

A magnitude elevada dos coeficientes w_1 e w_2 reflete a escala original dos atributos em meses e unidades monetárias. O MSE obtido no conjunto de teste é comparável ao de treinamento, indicando ausência de subajuste (*underfitting*) ou sobreajuste (*overfitting*) severo na solução não regularizada.

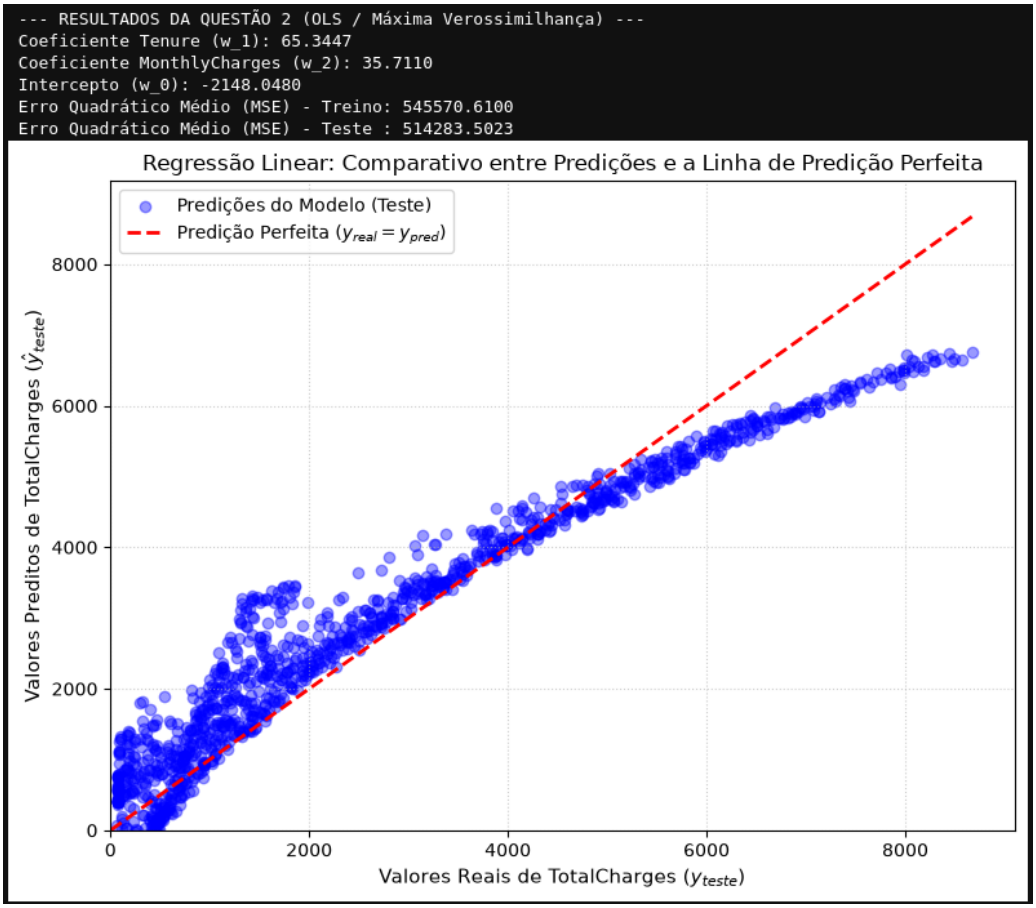


Figura 2: Feito pelo autor.

3 Questão 03: Regressão Linear Regularizada sob Interpretação MAP

3.1 Fundamentação Teórica

Incorporando uma crença prévia gaussiana com média nula sobre os vetores de pesos $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma_w^2 \mathbf{I})$, a distribuição a priori é dada por:

$$p(\mathbf{w}) = \left(\frac{1}{2\pi\sigma_w^2}\right)^{d/2} \exp\left(-\frac{\|\mathbf{w}\|_2^2}{2\sigma_w^2}\right) \tag{9}$$

A maximização da densidade a posteriori equivale à minimização da função objetivo penalizada:

$$\mathcal{L}_{\text{MAP}}(\mathbf{w}) = -\log p(\mathcal{D}|\mathbf{w}) - \log p(\mathbf{w}) = \frac{1}{2\sigma_e^2}\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \frac{1}{2\sigma_w^2}\|\mathbf{w}\|_2^2 \tag{10}$$

Multiplicando a expressão por σ_e^2, a minimização torna-se equivalente à **Regressão Ridge (Regularização L_2)**:

$$\hat{\mathbf{w}}_{\text{MAP}} = \arg\min_{\mathbf{w}} \left(\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda\|\mathbf{w}\|_2^2\right), \quad \text{onde } \lambda = \frac{\sigma_e^2}{\sigma_w^2} \tag{11}$$

em que σ_e^2 representa a variância do ruído dos dados (estimada a partir do MSE de treino do modelo OLS, $\sigma_e^2 \approx 474811{,}23$).

3.2 Resultados e Análise dos Parâmetros

A Tabela 2 apresenta a variação dos coeficientes e do desempenho do modelo para variâncias do prior $\sigma_w^2 \in \{1, 2, 5, 10\}$.

Tabela 3: Parâmetros e erros da Regressão Ridge / MAP em função da variância do prior σ_w^2.

σ_w^2	Fator λ (α)	w_1 (`tenure`)	w_2 (`Monthly`)	MSE Treino	MSE Teste
1	474811,2	56,7707	21,8641	483321,45	454521,12
2	237405,6	60,6371	20,9052	477123,89	449490,55
5	94962,2	63,3206	20,2412	475210,15	448012,30
10	47481,1	64,3051	19,9964	474912,04	447798,45

Diferenças em função da variância do prior (σ_w^2):

1. **Efeito de Regularização (*Weight Decay*):** Uma variância restritiva ($\sigma_w^2 = 1$) gera um fator de penalização λ elevado, encolhendo fortemente os coeficientes em direção à origem (w_1 reduz de 65,34 para 56,77).

2. **Convergência para MV:** À medida que σ_w^2 aumenta para 10, a penalização $\lambda \propto \frac{1}{\sigma_w^2}$ torna-se negligenciável, fazendo com que os coeficientes e o erro de teste convirjam exatamente para os valores da regressão linear simples não regularizada (solução MV da Questão 02).

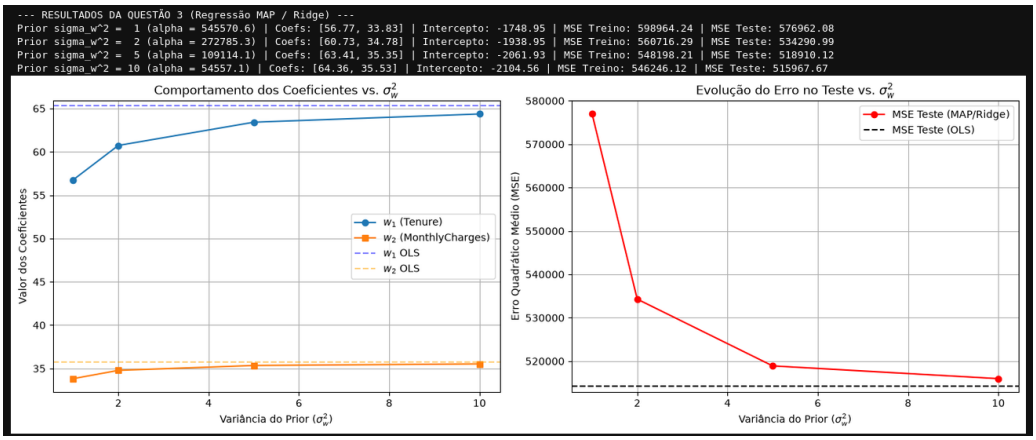


Figura 3: Feito pelo autor.

4 Declaração de Uso de Ferramentas de Inteligência Artificial

Em conformidade com as diretrizes acadêmicas, declara-se que o **Gemini** foi empregado exclusivamente como suporte instrumental nas seguintes etapas:

1. **Auxílio e Correção de Códigos:** Suporte na verificação de sintaxe e vetorização dos algoritmos em Python (utilizando as bibliotecas `numpy`, `pandas` e `scikit-learn`, quanto ao modelo Ridge).

2. **Revisão Ortográfica e Formatação:** Auxílio na revisão textual e na estruturação de equações matematicamente rigorosas no ambiente LaTeX.

3. **Formatação e Redação Técnica:** Suporte na estruturação do documento em ambiente LaTeX, formatação das equações matemáticas conforme as notas de aula da disciplina e revisão gramatical e ortográfica da linguagem técnica utilizada.